



温州大學  
WENZHOU UNIVERSITY

# 机器学习-降维

黄海广 副教授

2022年02月

# 本章目录

2

**01 降维概述**

**02 SVD(奇异值分解)**

**03 PCA(主成分分析)**

# 1.降维概述

3

## 01 降维概述

**02 SVD**(奇异值分解)


**03 PCA**(主成分分析)

# 1.降维概述

4

维数灾难(Curse of Dimensionality): 通常是指在涉及到向量的计算的问题中, 随着维数的增加, 计算量呈指数倍增长的一种现象。

在很多机器学习问题中, 训练集中的每条数据经常伴随着上千、甚至上万个特征。要处理这所有的特征的话, 不仅会让训练非常缓慢, 还会极大增加搜寻良好解决方案的困难。这个问题就是我们常说的维数灾难。



# 1.降维概述

5

## 维数灾难

维数灾难涉及数字分析、抽样、组合、机器学习、数据挖掘和数据库等诸多领域。在机器学习的建模过程中，通常指的是随着特征数量的增多，计算量会变得很大，如特征达到上亿维的话，在进行计算的时候是算不出来的。有的时候，维度太大也会导致机器学习性能的下降，并不是特征维度越大越好，模型的性能会**随着特征的增加先上升后下降**。

# 1.降维概述

6

## 什么是降维？

降维(Dimensionality Reduction)是将训练数据中的样本(实例)从高维空间转换到低维空间，该过程与信息论中有损压缩概念密切相关。同时要明白的，**不存在完全无损的降维。**

有很多种算法可以完成对原始数据的降维，在这些方法中，降维是通过对原始数据的线性变换实现的。

# 1.降维概述

7

## 为什么要降维

- 高维数据增加了运算的难度
- 高维使得学习算法的泛化能力变弱（例如，在最近邻分类器中，样本复杂度随着维度成指数增长），维度越高，算法的搜索难度和成本就越大。
- 降维能够增加数据的可读性，利于发掘数据的有意义的结构

# 1.降维概述

8

## 降维的主要作用

- 1.减少冗余特征，降低数据维度
- 2.数据可视化



# 1.降维概述

9

## 减少冗余特征

假设我们有两个特征：

$x_1$ :长度用厘米表示的身高； $x_2$ ：是用英寸表示的身高。

这两个分开的特征 $x_1$ 和 $x_2$ ，实际上表示的内容相同，这样其实可以减少数据到一维，只有一个特征表示身高就够了。

很多特征具有**线性关系**，具有线性关系的特征很多都是冗余的特征，去掉冗余特征对机器学习的计算结果不会有影响。

# 1.降维概述

10

数据可视化

## **t-distributed Stochastic Neighbor Embedding(t-SNE)**

t-SNE (TSNE) 将数据点之间的相似度转换为概率。原始空间中的相似度由高斯联合概率表示，嵌入空间的相似度由“学生t分布”表示。

虽然Isomap, LLE和variants等数据降维和可视化方法，更适合展开单个连续的低维的manifold。但如果要准确的可视化样本间的相似度关系，如下图所示的S曲线（不同颜色的图像表示不同类别的数据），t-SNE表现更好。因为**t-SNE主要是关注数据的局部结构**。

# 1.降维概述

11

## 降维的优缺点

降维的优点：

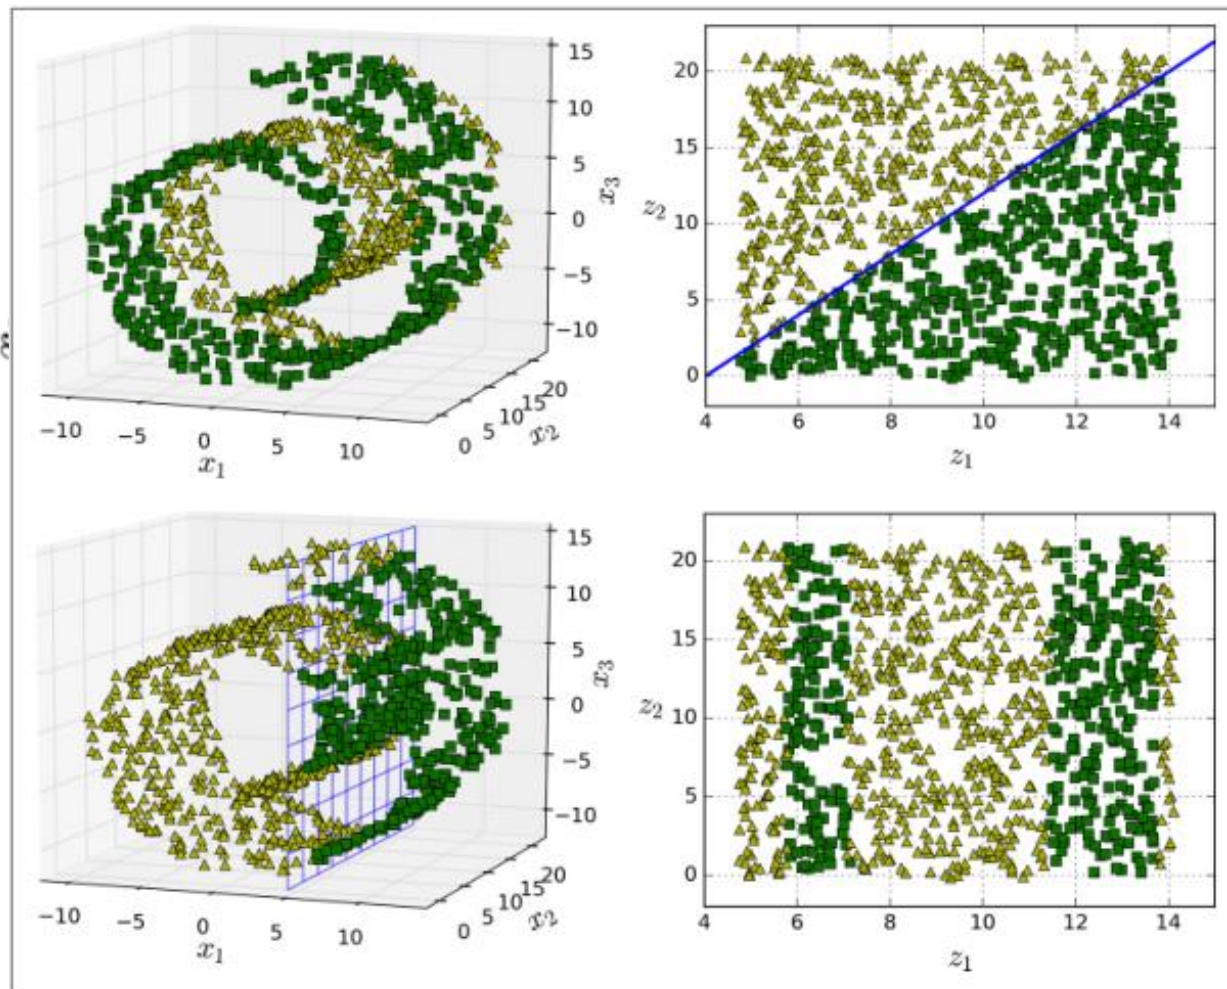

- 通过减少特征的维数，数据集存储所需的空间也相应减少，减少了特征维数所需的计算训练时间；
- 数据集特征的降维有助于快速可视化数据；
- 通过处理多重共线性消除冗余特征。

降维的缺点：

- 由于降维可能会丢失一些数据；
- 在主成分分析(PCA)降维技术中，有时需要考虑多少主成分是难以确定的，往往使用经验法则

# 1.降维概述

12



## 2.SVD(奇异值分解)

13

**01** 降维概述

**02 SVD(奇异值分解)**

**03 PCA(主成分分析)**

## 2.SVD(奇异值分解)

14

**奇异值分解 (Singular Value Decomposition, 以下简称 SVD)**是在机器学习领域广泛应用的算法, 它不光可以用于降维算法中的特征分解, 还可以用于推荐系统, 以及自然语言处理等领域。是很多机器学习算法的基石。

SVD可以将一个矩阵  $A$  分解为三个矩阵的乘积:

一个正交矩阵  $U$  (orthogonal matrix),

一个对角矩阵  $\Sigma$  (diagonal matrix),


一个正交矩阵  $V$  的转置。

## 2.SVD(奇异值分解)

15

假设矩阵  $A$  是一个  $m \times n$  的矩阵，通过SVD是对矩阵进行分解，  
那么我们定义矩阵  $A$  的 SVD 为：

$$A = U\Sigma V^T$$



## 2.SVD(奇异值分解)

16

### 符号定义

$$A = U\Sigma V^T = u_1\sigma_1v_1^T + \cdots + u_r\sigma_rv_r^T$$

其中 $U$ 是一个 $m \times m$ 的矩阵, 每个特征向量 $u_i$ 叫做 $A$  的左奇异向量。

$\Sigma$ 是一个 $m \times n$ 的矩阵, 除了主对角线上的元素以外全为 0, 主对角线上的每个元素都称为奇异值  $\sigma$ 。

$V$ 是一个 $n \times n$ 的矩阵, 每个特征向量 $v_i$ 叫做  $A$  的右奇异向量。

$U$  和  $V$ 都是酉矩阵, 即满足: $U^T U = I, V^T V = I$ 。

$r$ 为矩阵 $A$ 的秩(rank)。



## 2.SVD(奇异值分解)

17

### SVD求解 $U$ 矩阵求解

方阵 $AA^T$ 为 $m \times m$ 的一个方阵，那么我们就可以进行特征分解，得到的特征值和特征向量满足下式：

$$(AA^T)u_i = \lambda_i u_i$$

可以得到矩阵 $AA^T$ 的  $m$  个特征值和对应的  $m$ 个特征向量 $u$ 了。

## 2.SVD(奇异值分解)

18

### SVD求解 $U$ 矩阵求解

将 $AA^T$ 的所有特征向量组成一个  $m \times m$ 的矩阵 $U$ ，就是我们  $SVD$  公式里面的  $U$  矩阵了。

一般我们将 $U$ 中的每个特征向量叫做 $A$  的**左奇异向量**。

注意:  $AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U(\Sigma\Sigma^T)U^T$

上式证明使用了 $V^TV = I, \Sigma^T = \Sigma$ 。可以看出的 $AA^T$ 特征向量组成的矩阵就是我们  $SVD$  中的  $U$  矩阵。

## 2.SVD(奇异值分解)

19

$V$ 矩阵求解

如果我们将  $A$  的转置和  $A$  做矩阵乘法，那么会得到  $n \times n$  的一个方阵  $A^T A$ 。既然  $A^T A$  是方阵，那么我们就可以进行特征分解，得到的特征值和特征向量满足下式：

$$(A^T A)v_i = \lambda_i v_i$$

## 2.SVD(奇异值分解)

20

### 2.V矩阵求解

这样我们就可以得到矩阵 $A^T A$ 的  $n$ 个特征值和对应的 $n$ 个特征向量 $v$ 了。

将 $A^T A$ 的所有特征向量组成一个  $n \times n$  的矩阵 $V$ ，就是我们 SVD 公式里面的  $V$  矩阵了。一般我们将  $V$ 中的每个特征向量叫做  $A$  的右奇异向量。

注意：由于 $A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V (\Sigma^T \Sigma) V^T$

上式证明使用了 $U^T U = I, \Sigma^T = \Sigma$ 。可以看出 $A^T A$ 的特征向量组成的矩阵就是我们 SVD 中的  $V$  矩阵。

## 2.SVD(奇异值分解)

21

$\Sigma$  矩阵求解

进一步我们还可以看出我们的特征值矩阵等于奇异值矩阵的平方，也就

是说特征值和奇异值满足如下关系： $\sigma_i = \sqrt{\lambda_i}$

这样也就是说，我们可以不用  $\sigma_i = \frac{Av_i}{u_i}$  来计算奇异值，也可以通过求出

$A^T A$ 的特征值取平方根来求奇异值。

## 2.SVD(奇异值分解)

22

### 3. $\Sigma$ 矩阵求解

由于奇异值矩阵  $\Sigma$  除了对角线上是奇异值，而其他位置都是 0，那我们只需要求出每个奇异值  $\sigma$  就可以了。

我们注意到：

$$A = U\Sigma V^T, \text{ 则: } AV = U\Sigma V^T V$$

$$\text{由于: } V^T V = I, \text{ 则: } AV = U\Sigma$$

$$\text{得到: } Av_i = \sigma_i u_i, \sigma_i = Av_i / u_i$$

这样我们可以求出我们的每个奇异值，进而求出奇异值矩阵  $\Sigma$ 。

## 2.SVD(奇异值分解)

23

### SVD计算案例

设矩阵  $A$  定义为:  $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$  则  $A$  的秩  $r = 2$ 。

$$A^T A = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}$$

$$A A^T = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} = \begin{bmatrix} 9 & 12 \\ 12 & 41 \end{bmatrix}$$

两者都有相同的迹, 都是50。

## 2.SVD(奇异值分解)

24

### SVD计算案例

$$A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$$

进而求出  $A^T A$  的特征值和特征向量:

$$\begin{vmatrix} 25 - \lambda & 20 \\ 20 & 25 - \lambda \end{vmatrix} = (25 - \lambda)^2 - 400 = (\lambda - 45)(\lambda - 5) = 0$$

求解得到特征值:  $\lambda_1 = 45, \lambda_2 = 5$

由  $\sigma_i = \sqrt{\lambda_i}$ , 可以得到奇异值为:  $\sigma_1 = \sqrt{45}, \sigma_2 = \sqrt{5}$



## 2.SVD(奇异值分解)

25

接着求出  $AA^T$  的特征值和特征向量:

同理求得:  $\lambda_1 = 45, \lambda_2 = 5$

$$v_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 1 \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \quad v_2 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ 1 \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

利用  $Av_i = \sigma_i u_i, i = 1, 2$ , 求奇异值:

$$Av_1 = \begin{bmatrix} \frac{3}{\sqrt{2}} \\ 9 \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{45} \begin{bmatrix} \frac{1}{\sqrt{10}} \\ 3 \\ \frac{1}{\sqrt{10}} \end{bmatrix} = \sigma_1 u_1, \quad Av_2 = \begin{bmatrix} -\frac{3}{\sqrt{2}} \\ 1 \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{5} \begin{bmatrix} -\frac{3}{\sqrt{10}} \\ 1 \\ \frac{1}{\sqrt{10}} \end{bmatrix} = \sigma_2 u_2$$

## 2.SVD(奇异值分解)

26

最终得到  $A$  的奇异值分解为：

$$U = \begin{bmatrix} \frac{1}{\sqrt{10}} & -\frac{3}{\sqrt{10}} \\ \frac{3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sqrt{45} & 0 \\ 0 & \sqrt{5} \end{bmatrix}, \quad V = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$
$$A = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{10}} & -\frac{3}{\sqrt{10}} \\ \frac{3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \end{bmatrix} \begin{bmatrix} \sqrt{45} & 0 \\ 0 & \sqrt{5} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}^T = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$$

同理：

$$A = U\Sigma V^T = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T$$

## 2.SVD(奇异值分解)

27

SVD分解可以将一个矩阵进行分解，对角矩阵对角线上的特征值递减存放，而且奇异值的减少特别的快，在很多情况下，前 10%甚至 1%的奇异值的和就占了全部的奇异值之和的 99%以上的比例。

也就是说，对于奇异值，它跟我们特征分解中的特征值类似，我们也可以用最大的  $k$  个的奇异值和对应的左右奇异向量来近似描述矩阵。

也就是说：

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T \approx U_{m \times k} \Sigma_{k \times k} V_{k \times n}^T$$

## 2.SVD(奇异值分解)


28

其中  $k$  要比  $n$  小很多, 也就是一个大的矩阵  $A$  可以用三个小的矩阵

$U_{m \times k}, \Sigma_{k \times k}, V_{k \times n}^T$  来表示。

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T \approx U_{m \times k} \Sigma_{k \times k} V_{k \times n}^T$$


如图所示, 现在我们的矩阵  $A$  只需要黄色的部分的三个小矩阵就可以近似描述了。



## 2.SVD(奇异值分解)

29

### SVD案例




原始图像

$$m = 575, \quad n = 1081, \quad k = 150$$

$$\text{原始维度} A = 575 \times 1081 \times 3 = 1864725$$

$$\text{则原始图像经过压缩后的维度: } 3 \times (575 \times 150 + 150 \times 150 + 1081 \times 150) = 812700$$



处理后的图像

设  $k = 150$ , 则经过SVD分解后的矩阵及维度:

$$U_{m \times k} = 575 \times 150, \quad \Sigma_{k \times k} = 150 \times 150, \quad V_{k \times n}^T = 1081 \times 150$$

# 3.PCA(主成分分析)

30

**01** 降维概述

**02 SVD**(奇异值分解)

**03 PCA**(主成分分析)

# 3.PCA(主成分分析)

31

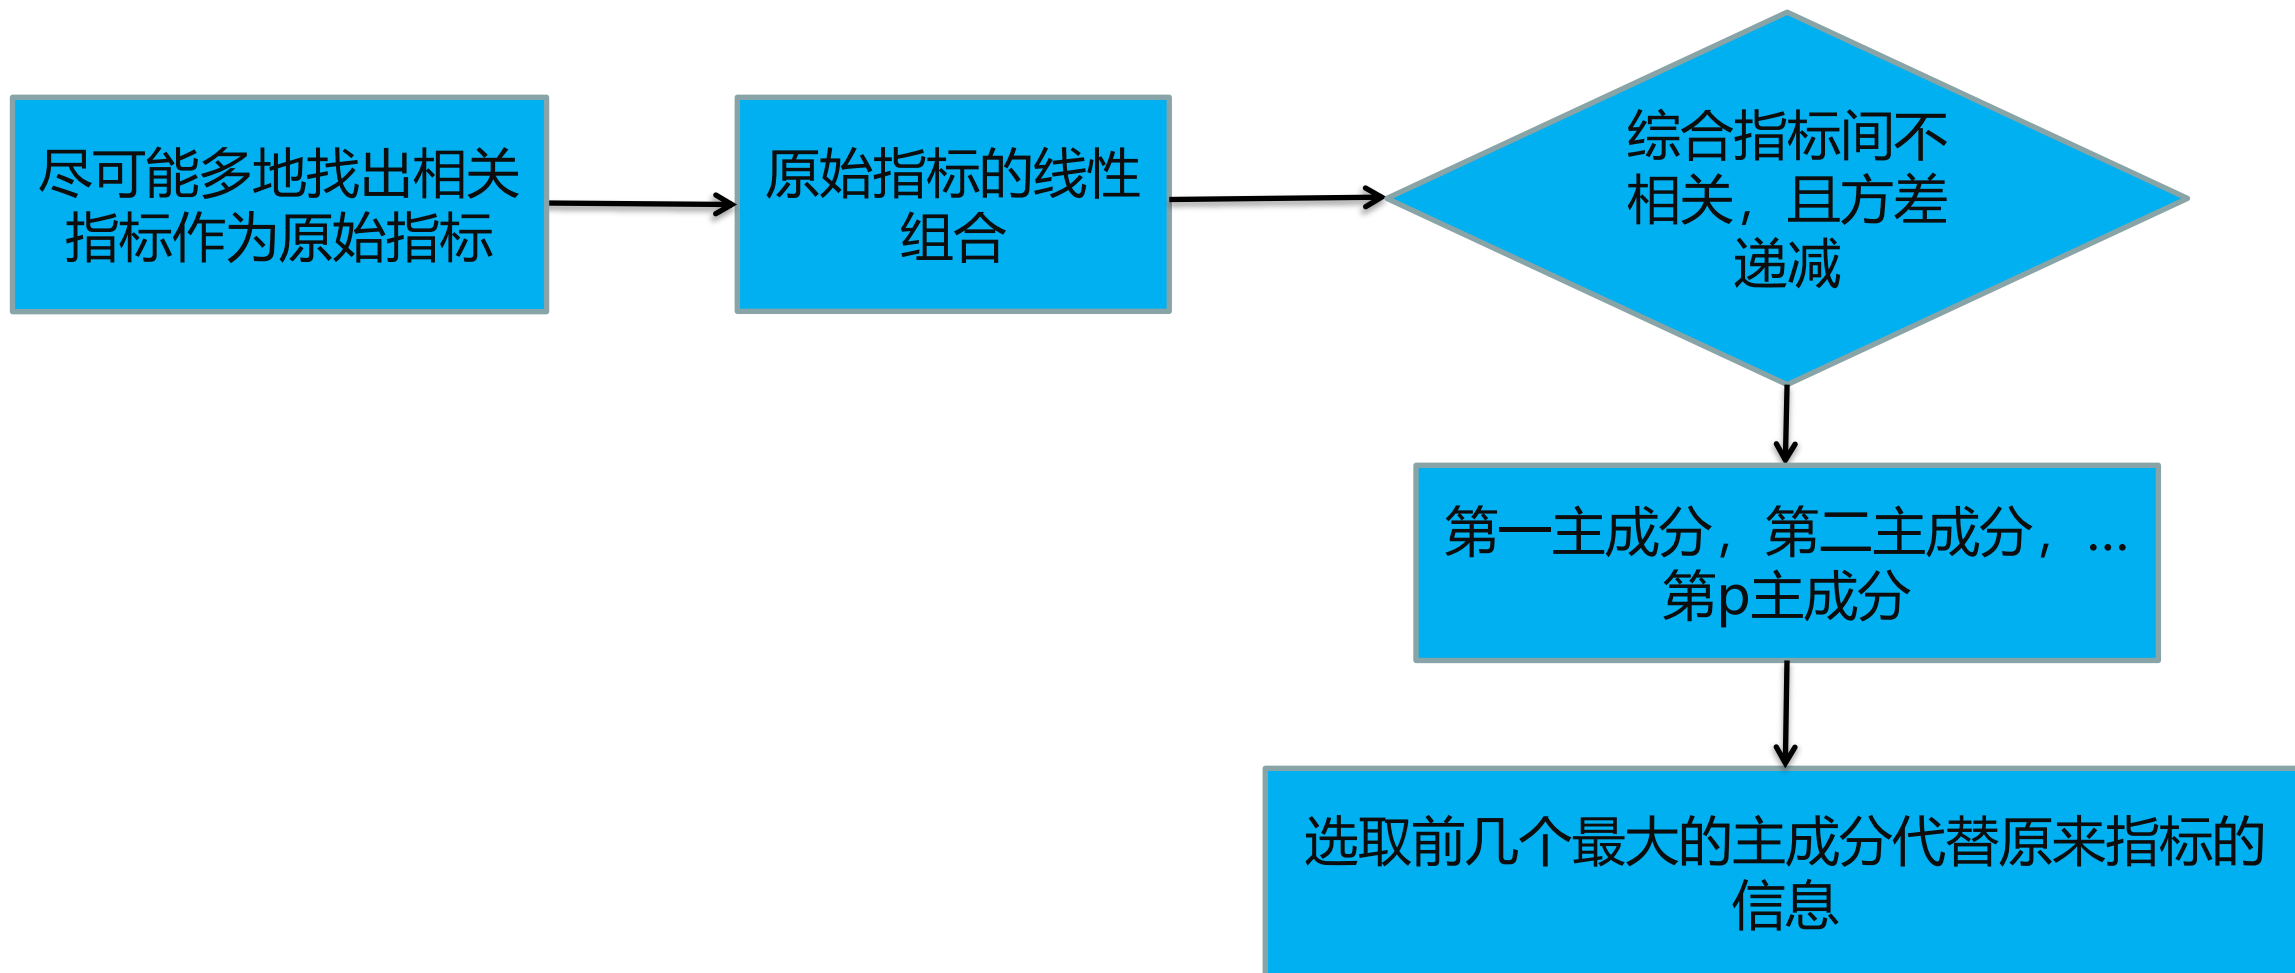
**主成分分析 (Principal Component Analysis,PCA)** 是一种降维方法, 通过将一个大的特征集转换成一个较小的特征集, 这个特征集**仍然包含了原始数据中的大部分信息**, 从而降低了原始数据的维数。

减少一个数据集的特征数量自然是以牺牲准确性为代价的, 但降维的诀窍是用一点准确性换取简单性。因为更小的数据集更容易探索和可视化, 并且对于机器学习算法来说, 分析数据会更快、更容易, 而不需要处理额外的特征。

### 3.PCA(主成分分析)

32

主成分分析流程图：






### 3.PCA(主成分分析)

33


主成分分析的几何解释



平移、旋转坐标轴

### 3.PCA(主成分分析)



34



PCA的思想很简单——减少数据集的特征数量，同时尽可能地保留信息。

# 3.PCA(主成分分析)

35



通过平移、旋转坐标轴，找到主成分pc1和pc2

# 3.PCA(主成分分析)

36

PCA识别在训练集中占最大方差量的轴。

在图1中，它是实线。它还找到与第一个轴正交的第二个轴，它考虑了剩余方差的最大量。在这个2D示例中，它是虚线。如果它是一个更高维的数据集，PCA还会找到与前两个轴正交的第三个轴，以及第四个，第五个等等 - 与数据集中的维数一样多的轴。

**定义第  $i$  轴的单位向量称为第  $i$  个主成分 (PC)。**

- 在图1中，第一个 **PC**为  $c_1$ ，第二个 **PC** 为  $c_2$ 。
- 在图2中，前两个 **PC**由平面中的正交箭头表示，第三个 **PC**与平面正交（向上或向下）。




图1 选择要投影到的子空间




图2

# 3.PCA(主成分分析)

37

**如何得到这些包含最大差异性的主成分方向呢？**

通过计算数据矩阵的协方差矩阵

然后得到协方差矩阵的特征值特征向量

选择特征值最大(即方差最大)的k个特征所对应的特征向量组成的矩阵。

这样就可以将数据矩阵转换到新的空间当中，实现数据特征的降维。

# 3.PCA(主成分分析)

38

## PCA的算法两种实现方法

- (1) 基于SVD分解协方差矩阵实现PCA算法
- (2) 基于特征值分解协方差矩阵实现PCA算法

# 3.PCA(主成分分析)

39

## (1)基于SVD分解协方差矩阵实现PCA算法

**PCA** 减少 $n$ 维到 $k$ 维:

设有 $m$ 条 $n$ 维数据, 将原始数据按列组成 $n$ 行 $m$ 列矩阵 $X$

第一步是均值归一化。我们需要计算出所有特征的均值, 然后令  $x_j = x_j - \mu_j$ 。 ( $\mu_j$ 为均值)。如果特征是在不同的数量级上, 我们还需要将其除以标准差  $\sigma^2$ 。

第二步是计算**协方差矩阵** (**covariance matrix**)  $\Sigma$ :


$$\Sigma = \frac{1}{m} \sum_{i=1}^n (x^{(i)}) (x^{(i)})^T$$

第三步是计算协方差矩阵 $\Sigma$ 的**特征向量** (**eigenvectors**) ,可以利用奇异值分解(SVD)来求解。

### 3.PCA(主成分分析)

40

**奇异值分解 (SVD)** 的标准矩阵分解技术可以将训练集矩阵  $A$  分解为三个矩阵  $U \cdot \Sigma \cdot V^T$  的点积, 其中  $V^T$  包含我们正在寻找的所有主成分。





# 3.PCA(主成分分析)

41

## (2) 基于特征值分解协方差矩阵实现PCA算法

背景知识

### 1) 特征值与特征向量

如果一个向量 $v$ 是矩阵 $A$ 的特征向量，将一定可以表示成下面的形式：

$$Av = \lambda v$$

其中， $\lambda$ 是特征向量 $A$ 对应的特征值，一个矩阵的一组特征向量是一组正交向量。

# 3.PCA(主成分分析)

42

## (2) 基于特征值分解协方差矩阵实现PCA算法

### 2) 特征值分解矩阵

对于矩阵 $A$ ，有一组特征向量 $v$ ，将这组向量进行正交化单位化，就能得到一组正交单位向量。特征值分解，就是将矩阵 $A$ 分解为如下式：

$$A = P\Sigma P^{-1}$$

其中， $P$ 是矩阵 $A$ 的特征向量组成的矩阵， $\Sigma$ 则是一个对角阵，对角线上的元素就是特征值。

备注：对于正交矩阵 $P$ ，有 $P^{-1} = P^T$

# 3.PCA(主成分分析)

43

## (2) 基于特征值分解协方差矩阵实现PCA算法

设有 $m$ 条 $n$ 维数据，将原始数据按列组成 $n$ 行 $m$ 列矩阵 $X$

1) 均值归一化。我们需要计算出所有特征的均值，然后令  $x_j = x_j - \mu_j$ 。 ( $\mu_j$ 为均值) 。

如果特征是在不同的数量级上，我们还需要将其除以标准差  $\sigma^2$ 。

2) 计算协方差矩阵 $\Sigma$ 。  $\Sigma = \frac{1}{m} \sum_{i=1}^n (x^{(i)})(x^{(i)})^T$

3) 用特征值分解方法计算协方差矩阵 $\Sigma$ 的特征值和特征向量。

4) 对特征值从大到小排序，选择其中最大的 $k$ 个。然后将其对应的 $k$ 个特征向量分别作为行向量组成特征向量矩阵 $P$ 。

5) 将数据转换到 $k$ 个特征向量构建的新空间中，即  $Y = PX$ 。

# 3.PCA(主成分分析)

44

## PCA的算方案例

$$X = \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

以这个为例，我们用PCA的方法将这组二维数据降到一维

因为这个矩阵的每行已经是零均值，所以我们可以直接求协方差矩阵：

$$\Sigma = \frac{1}{5} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1 & -2 \\ -1 & 0 \\ 0 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix}$$

### 3.PCA(主成分分析)

45

然后求 $\Sigma$ 的特征值和特征向量:

$$|A - \lambda E| = \begin{vmatrix} \frac{6}{5} - \lambda & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} - \lambda \end{vmatrix} = (\frac{6}{5} - \lambda)^2 - \frac{16}{25} = (\lambda - 2)(\lambda - 2/5) = 0$$

求解得到特征值:  $\lambda_1 = 2, \lambda_2 = 2/5$

其对应的特征向量分别是:  $\Sigma_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \Sigma_2 \begin{pmatrix} -1 \\ 1 \end{pmatrix}$

### 3.PCA(主成分分析)

46

由于对应的特征向量分别是一个通解， $\Sigma_1$ 和 $\Sigma_2$ 可取任意实数。那么标准化后的特征向量为：

$$\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

因此我们的矩阵 $P$ 是：

$$P = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

# 3.PCA(主成分分析)

47

可以验证协方差矩阵 $\Sigma$ 的对角化

$$P\Sigma P^T = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 6/5 & 4/5 \\ 4/5 & 6/5 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2/5 \end{pmatrix}$$


最后我们用 $P$ 的第一行乘以数据矩阵，就得到了降维后的数据表示：

$$Y = (1/\sqrt{2} \quad 1/\sqrt{2}) \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} -3/\sqrt{2} & -1/\sqrt{2} & 0 & 3/\sqrt{2} & -1/\sqrt{2} \end{pmatrix}$$

### 3.PCA(主成分分析)

48

降维后的投影结果如下图：





# 3.PCA(主成分分析)

49

## PCA算法优点

1. 仅仅需要以方差衡量信息量,不受数据集以外的因素影响
2. 各主成分之间正交,可消除原始数据成分间的相互影响的因素
3. 计算方法简单,主要运算时特征值分解,易于实现
4. 它是无监督学习,完全无参数限制的

## PCA算法缺点

1. 主成分各个特征维度的含义具有一定的模糊性,不如原始样本特征的解释性强
2. 方差小的非主成分也可能含有对样本差异的重要信息,因降维丢弃可能对后续数据处理有影响

- [1] Andrew Ng. Machine Learning[EB/OL].  
StanfordUniversity,2014.<https://www.coursera.org/course/ml>
- [2] Hinton, G, E, et al. Reducing the Dimensionality of Data with Neural Networks.[J].  
Science, 2006.
- [3] Jolliffe I T . Principal Component Analysis[J]. Journal of Marketing Research, 2002,  
87(4):513.
- [4] 李航. 统计学习方法[M]. 北京: 清华大学出版社,2019.
- [5] Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning[M]. New York:  
Springer,2001.
- [6] Peter Harrington.机器学习实战[M]. 北京:人民邮电出版社,2013.

谢谢!

